GolubWDBC

Appliquer le vote pondéré de Golub au jeu de données WDBC

Machine Learning pour la biologie appliquée

EPITA - ING3 - Santé & IA

16 octobre 2026

Auteur

clovis.thoreton



Table des matières

Résumé 1

Introduction 1

1 Exploration des données 2

2 Implémentation du vote pondéré 4

3 Évaluation du modèle 6

4 Stabilité de la sélection des variables 8

5 Comparaison avec la régression logistique 10

6 Conclusion sur la question clinique 12

7 Reproductibilité de la méthode de l'article 12

Bibliographie 13

Glossaire 14

Résumé

Ce rapport applique le vote pondéré de Golub et al. (1999) au jeu Wisconsin Diagnostic Breast Cancer (WDBC), qui décrit 569 patients par 30 mesures des noyaux de leurs cellules. Le modèle est évalué par validation croisée stratifiée à cinq folds répétée trois fois, avec la seed 29, puis comparé à une régression logistique sur les mêmes découpages. Le vote pondéré obtient une AUC moyenne de 0,961 et une balanced accuracy moyenne de 0,857, contre 0,994 et 0,972 pour la régression logistique. Sa sélection de variables est très stable, avec un Jaccard moyen de 0,955, mais ses performances varient d'un modèle à l'autre, et son vote repose presque uniquement sur l'aire du noyau. La méthode n'est donc pas recommandable en l'état pour le diagnostic.

Introduction

Golub et al. ont classé en 1999 des échantillons de leucémie à partir de l'expression de leurs gènes. Leur méthode ne retient qu'un petit nombre de gènes, donne un poids à chacun, puis combine ces gènes pondérés pour décider de la classe d'un échantillon. [1] Ce rapport applique cette méthode, dite de vote pondéré, au diagnostic du cancer du sein, à partir de mesures faites sur des images de cellules prélevées à l'aiguille fine. Conçue pour des données d'expression des gènes, la méthode est ici transposée à des mesures d'images, d'où la question suivante. La méthode de vote pondéré de Golub peut-elle classer avec précision et de façon robuste les prélèvements mammaires malins ?

Les données sont celles du jeu WDBC, déposé dans le dépôt UCI en 1995 par Wolberg, Street et Mangasarian. [2] Il contient les 569 patients consécutifs qui ont servi à construire le système de leur article de 1994, et dont une masse mammaire avait déjà été prélevée. [3] Pour chaque patient, les cellules prélevées sont converties en image, puis 30 mesures des noyaux cellulaires en sont tirées. [4] Le modèle ne reçoit que ces 30 mesures et le diagnostic, la classe maligne étant codée 1 et la classe bénigne 0. Les 54 patients de test externe de l'article de 1994 ne font pas partie du jeu.

L'analyse est produite par la commande `uv run main.py`, dans le dépôt `https://github.com/Ryieru/GolubWDBC`, avec Python 3.13.13, numpy 2.5.3, pandas 3.0.6, scikit-learn 1.9.1 [5] et matplotlib 3.11.2. La seed personnelle vaut 29.

1. Golub TR et al. (1999). Molecular classification of cancer, class discovery and class prediction by gene expression monitoring, *Science*, volume 286, numéro 5439, pages 531 à 537. `https://doi.org/10.1126/science.286.5439.531`

2. Wolberg W, Mangasarian O, Street N, Street W. Breast Cancer Wisconsin (Diagnostic), UCI Machine Learning Repository. `https://doi.org/10.24432/C5DW2B`

3. Wolberg WH, Street WN, Mangasarian OL (1994). Machine learning techniques to diagnose breast cancer from image-processed nuclear features of fine needle aspirates, *Cancer Letters*, volume 77, numéros 2 et 3, pages 163 à 171. `https://doi.org/10.1016/0304-3835(94)90099-X`

4. Street WN, Wolberg WH, Mangasarian OL (1993). Nuclear feature extraction for breast tumor diagnosis, *IS&T/SPIE Symposium on Electronic Imaging*, volume 1905, pages 861 à 870. `https://doi.org/10.1117/12.148698`

5. Pedregosa F et al. (2011). Scikit-learn, machine learning in Python, *Journal of Machine Learning Research*, volume 12, pages 2825 à 2830. `https://jmlr.org/papers/v12/pedregosa11a.html`

1 Exploration des données

Le jeu contient 569 patients et 30 variables, sans valeur manquante. La figure 1 montre qu'il compte 357 patients bénins (62,7 %) et 212 malins (37,3 %). Les classes sont donc déséquilibrées.

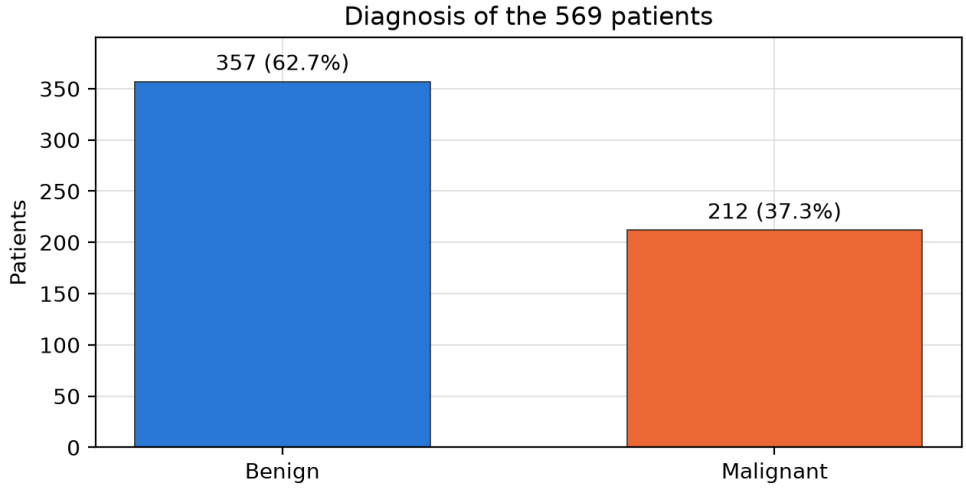


FIGURE 1 – Nombre de patients bénins et malins parmi les 569 patients du jeu (`results/figures/1_diagnosis_counts.png`).

Les 30 variables décrivent les noyaux des cellules visibles sur l'image de chaque prélèvement. Le noyau est la partie de la cellule qui contient l'ADN, et chacun est repéré sur l'image avant d'être mesuré. Dix propriétés sont calculées sur chaque noyau, et décrivent trois aspects différents.

- La taille du noyau, avec le rayon, le périmètre et l'aire.
- La forme de son contour, avec la régularité (smoothness, variation locale du rayon), la compacité, la concavité, les points concaves (nombre ou étendue des creux du contour), la symétrie et la dimension fractale, qui mesure la complexité du contour.
- Sa texture, c'est-à-dire l'écart-type des niveaux de gris du noyau sur l'image.

Une image contient plusieurs noyaux. Chaque propriété est donc résumée par trois valeurs, la moyenne sur les noyaux (préfixe `mean_`), l'erreur standard (suffixe `_error`) et la moyenne des trois plus grandes valeurs (préfixe `worst_`). Dix propriétés résumées de trois façons donnent ainsi les 30 variables. Leurs échelles diffèrent fortement, de quelques centièmes pour `mean_fractal_dimension` à plusieurs centaines pour `mean_area` et `worst_area`.

Le lien de chaque variable avec le diagnostic est décrit par sa moyenne et son écart-type dans chaque classe, et par son AUC, en prenant la valeur brute de la variable comme score de malignité. Cette description, calculée sur les 569 patients, n'intervient pas dans la sélection des variables. La figure 2 classe les 30 variables par AUC.

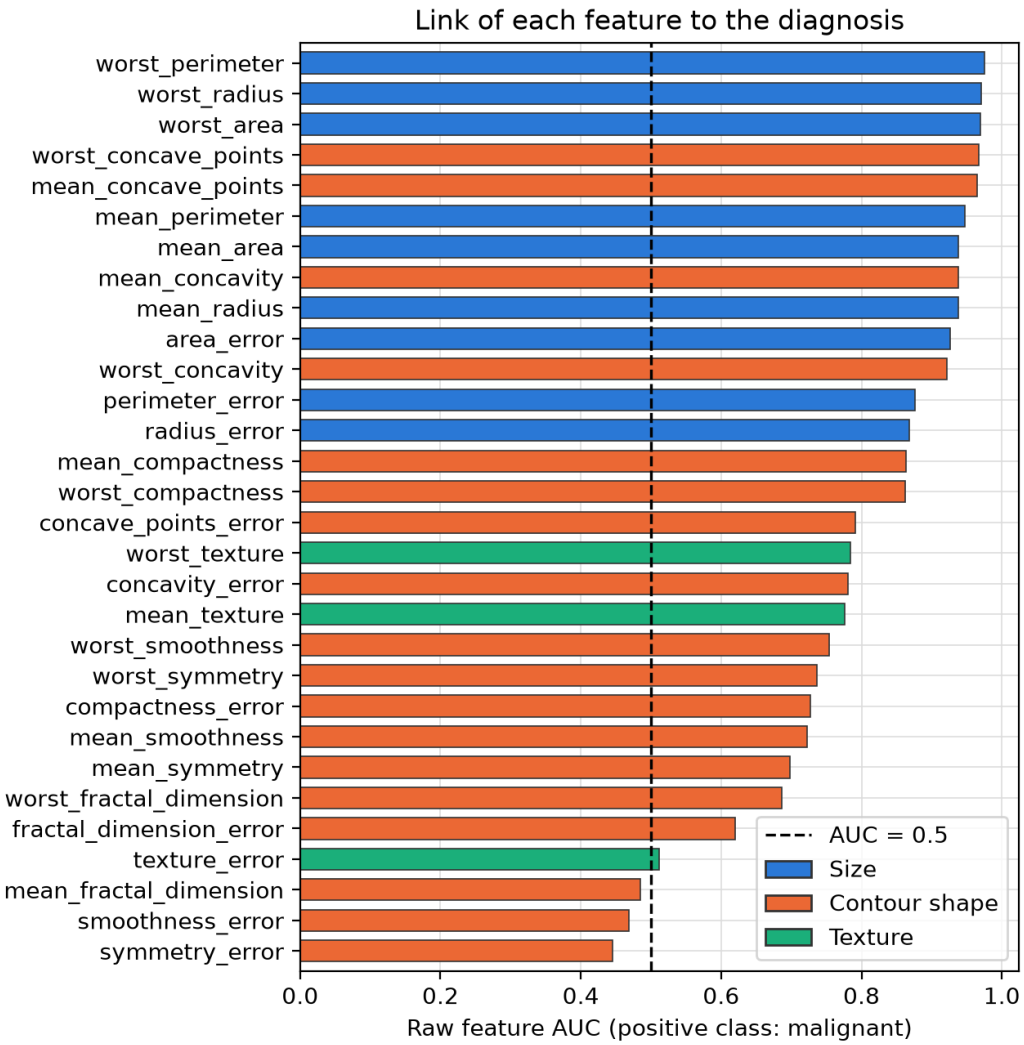


FIGURE 2 – AUC de chaque variable brute pour prédire la classe maligne, sur les 569 patients. La couleur indique l'aspect du noyau mesuré, et la ligne pointillée l'AUC de 0,5 d'une variable qui ne sépare pas les classes (`results/figures/1_feature_aucs.png`).

La figure 2 montre que le haut du classement est occupé par les variables de taille, en bleu, et de forme du contour, en orange. Les 11 variables dont l'AUC dépasse 0,9 appartiennent toutes à ces deux groupes, et les quatre premières sont des versions `worst_`, celles du périmètre (`worst_perimeter`, 0,975), du rayon (`worst_radius`, 0,970), de l'aire (`worst_area`, 0,970) et des points concaves (`worst_concave_points`, 0,967). Leur AUC supérieure à 0,5 signifie qu'elles sont plus élevées chez les malins. Les deux variables de texture, en vert, se placent au milieu du classement (`worst_texture`, 0,785 et `mean_texture`, 0,776). Pour neuf des dix propriétés, l'erreur standard a une AUC plus faible que la moyenne et la pire valeur, la dimension fractale faisant seule exception (`fractal_dimension_error`, 0,620 contre `mean_fractal_dimension`, 0,485). Le bas de la figure regroupe quatre variables proches de la ligne pointillée, qui ne séparent presque pas les deux classes. Ce sont l'erreur standard de la texture (`texture_error`, 0,512), la dimension fractale moyenne (`mean_fractal_dimension`, 0,485) et l'erreur standard de la régularité du contour (`smoothness_error`, 0,469) et de la symétrie (`symmetry_error`, 0,445). Les trois dernières passent légèrement sous 0,5, et sont donc un peu plus basses chez les malins.

2 Implémentation du vote pondéré

Pour chaque variable j, le poids est calculé sur le fold d'entraînement à partir des moyennes μ et des écarts-types σ de chaque classe, l'indice 1 désignant la classe maligne et l'indice 0 la classe bénigne.

$$w_j = \frac{\mu_{j,1} - \mu_{j,0}}{\sigma_{j,1} + \sigma_{j,0}}$$

Les dix variables de plus grand $|w_j|$ forment l'ensemble S. Pour un patient x, le vote total compare chaque valeur au point milieu des deux moyennes, et le patient est prédit malin lorsque $V(x) \geq 0$.

$$V(x) = \sum_{j \in S} w_j \left(x_j - \frac{\mu_{j,1} + \mu_{j,0}}{2} \right)$$

Le modèle est la classe `WeightedVoting`. Il est construit à partir du seul jeu d'entraînement d'un fold, en quatre étapes.

1. Les patients d'entraînement sont séparés selon leur diagnostic, puis la moyenne et l'écart-type de chacune des 30 variables sont calculés dans chaque classe, avec pandas. Cette étape est faite par la classe `DiagnosisStatistics`, instanciée une fois pour les malins et une fois pour les bénins.
2. Pour chaque variable, le poids w_j est l'écart entre la moyenne des malins et celle des bénins, divisé par la somme des deux écarts-types, et le point milieu est la moyenne des deux moyennes.
3. Les 30 variables sont classées par $|w_j|$ décroissant, et les dix premières sont conservées avec leur poids et leur point milieu. En cas d'égalité au dixième rang, la variable conservée est la première dans l'ordre des colonnes.
4. Pour prédire un patient, chaque variable vote avec l'écart entre la valeur du patient et le point milieu, multiplié par le poids. La somme des dix votes donne $V(x)$, et le patient est prédit malin lorsque $V(x) \geq 0$.

Ces étapes sont refaites dans chacun des 15 folds d'entraînement. Chaque modèle a donc ses propres poids, ses propres points milieux et ses dix variables.

Le modèle entraîné sur le fold 1 de la répétition 1, noté R1F1 et appelé modèle exemple dans la suite, illustre ces étapes. La figure 3 donne la contribution moyenne de chacune de ses dix variables au vote, sur ses 114 patients de validation.

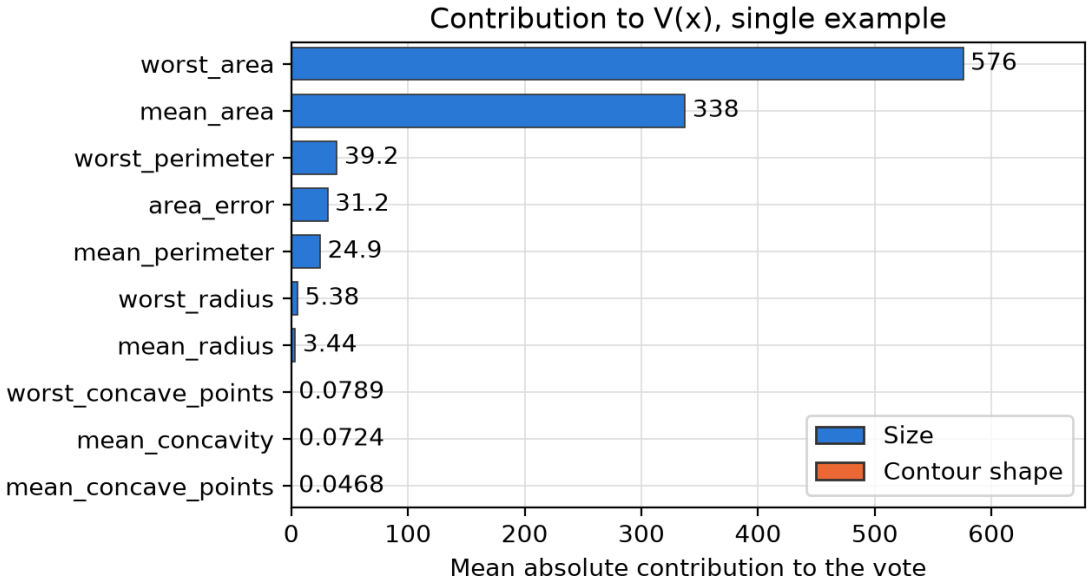


FIGURE 3 – Contribution moyenne de chacune des dix variables au vote $V(x)$ du modèle exemple, en valeur absolue, sur ses 114 patients de validation (`results/figures/2_vote_contributions.png`).

Les deux variables d'aire, `worst_area` (576) et `mean_area` (338), ont de loin les plus fortes contributions, devant `worst_perimeter` (39,2). Les trois variables de forme du contour, `worst_concave_points` (0,0789), `mean_concavity` (0,0724) et `mean_concave_points` (0,0468), ne pèsent presque rien. La figure 4 donne la valeur absolue des 30 poids du même modèle.

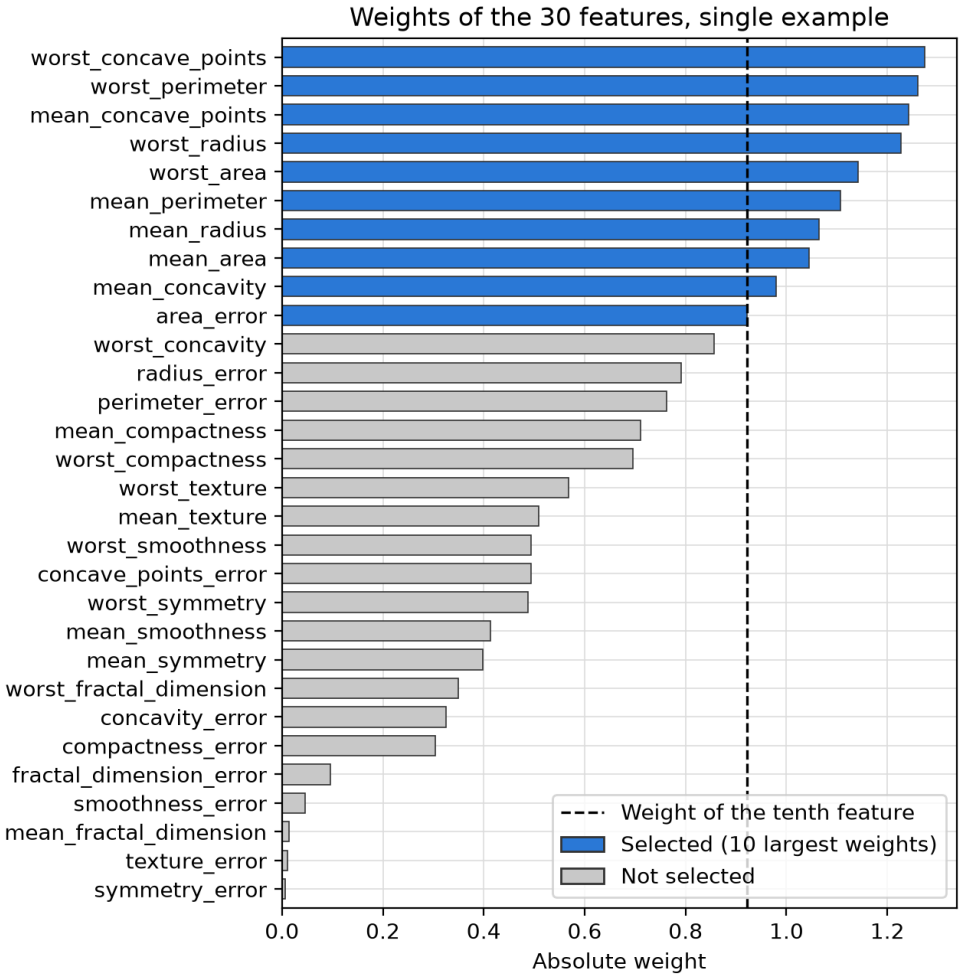


FIGURE 4 – Valeur absolue du poids w_j des 30 variables dans le modèle exemple. Les dix plus grandes, en bleu, forment l'ensemble S, et la ligne pointillée marque le poids de la dixième (`results/figures/2_feature_weights.png`).

Les dix variables retenues ont des poids proches, de 0,922 pour `area_error` à 1,274 pour `worst_concave_points`. La onzième, `worst_concavity`, reste juste sous le seuil. Des poids proches ne donnent donc pas la même influence sur le vote.

3 Évaluation du modèle

L'évaluation est faite par la classe `Evaluation`, en quatre étapes.

1. Les 569 patients sont découpés en validation croisée stratifiée par la classe `RepeatedStratifiedKFold` du module `sklearn.model_selection` de scikit-learn, avec cinq folds (`n_splits=5`), trois répétitions (`n_repeats=3`) et la seed 29 (`random_state=29`). À chaque répétition, les patients sont mélangés puis répartis en cinq groupes d'environ 114 patients qui conservent la proportion de bénins et de malins. Chaque découpage est gardé dans la classe `Split`, sous la forme des indices des patients d'entraînement et de validation.
2. Chaque découpage donne un `Fold`, qui contient le jeu d'entraînement d'environ 455 patients, le jeu de validation d'environ 114 patients, le numéro de la répétition et celui du fold. Les 15 folds sont notés par leur répétition et leur fold, R1F1 désignant le fold 1 de la répétition 1.
3. Un modèle de vote pondéré est entraîné sur le jeu d'entraînement de chaque fold, ce qui donne 15 modèles. Chaque patient est prédit trois fois, chaque fois par un modèle qui ne l'a jamais vu.
4. La classe `FoldResult` calcule les votes $V(x)$ et les prédictions du modèle sur son jeu de validation. La classe `Metrics` en tire ensuite l'AUC, la balanced accuracy et la matrice de confusion avec le module `sklearn.metrics`, le vote $V(x)$ servant de score pour l'AUC.

La moyenne et l'écart-type de l'AUC et de la balanced accuracy sont ensuite calculés sur les 15 modèles, et le modèle R1F1 sert de modèle exemple.

Deux métriques sont calculées sur chaque fold de validation. L'AUC mesure la capacité du score $V(x)$ à placer les malins au-dessus des bénins, indépendamment du seuil. La balanced accuracy est la moyenne de la sensibilité (part des malins prédits malins) et de la spécificité (part des bénins prédits bénins), et dépend donc du seuil $V(x) \geq 0$. Contrairement à l'accuracy, elle donne le même poids aux deux classes, quel que soit leur nombre de patients.

Le modèle exemple R1F1 est évalué sur 114 patients, dont 71 bénins et 43 malins. La figure 5 donne sa matrice de confusion.

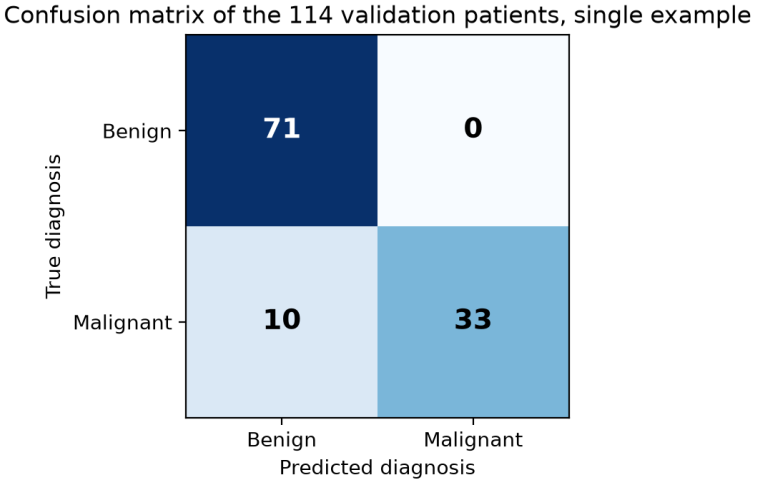


FIGURE 5 – Matrice de confusion du modèle exemple sur ses 114 patients de validation. Les lignes donnent le diagnostic réel et les colonnes le diagnostic prédit (`results/figures/3_single_example_confusion_matrix.png`).

Ce modèle obtient une AUC de 0,973 et une balanced accuracy de 0,884. Les 71 bénins sont tous bien classés, soit une spécificité de 100 %, mais 10 des 43 malins sont prédits bénins, soit une sensibilité de 76,7 %. Toutes les erreurs vont dans le même sens. La figure 6 range les 114 patients par vote croissant pour situer ces erreurs.

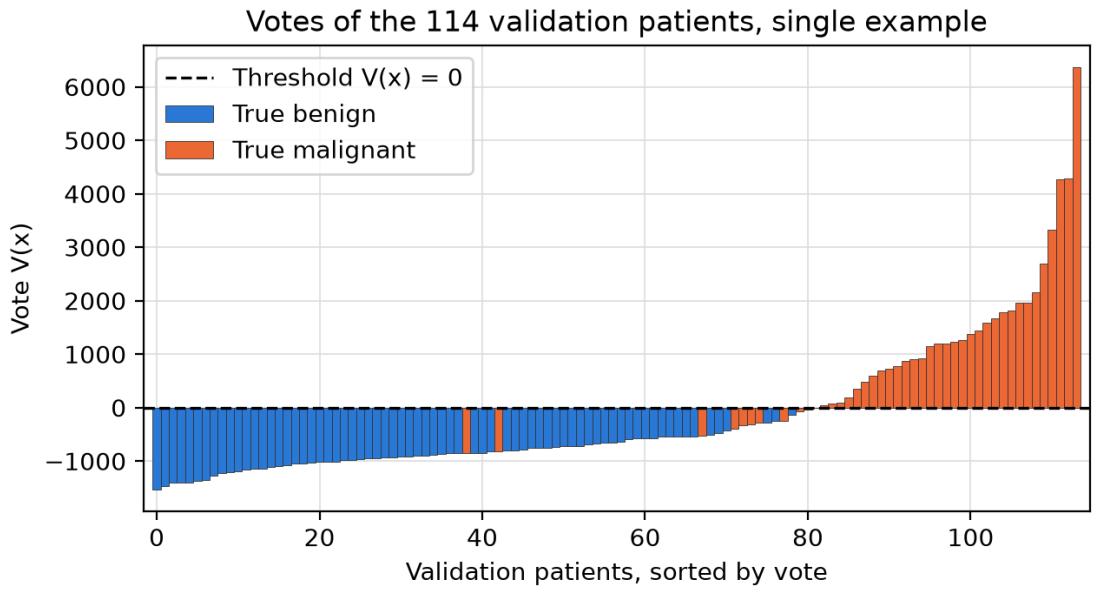


FIGURE 6 – Vote $V(x)$ des 114 patients de validation du modèle exemple, rangés par vote croissant et colorés par diagnostic réel. Un patient est prédit malin lorsque sa barre dépasse la ligne pointillée (`results/figures/3_single_example_votes.png`).

Les bénins ont tous un vote négatif. Les malins sont presque tous regroupés à droite, ce qui donne l'AUC de 0,973, mais 10 d'entre eux restent sous 0, dont certains au milieu des bénins.

	AUC	Balanced accuracy
Moyenne	0,961	0,857
Écart-type	0,017	0,042
Minimum	0,923	0,781
Maximum	0,982	0,929

TABLE 1 – AUC et balanced accuracy du vote pondéré sur les 15 modèles (`results/tables/3_evaluation.csv`). Les valeurs de chaque modèle sont à la figure 9.

Sur les 15 modèles, l'AUC moyenne vaut 0,961 et la balanced accuracy moyenne 0,857. L'écart de 0,104 entre les deux métriques retrouve à l'échelle des 15 modèles le défaut observé sur l'exemple. Le score sépare bien les classes, mais le seuil fixe $V(x) \geq 0$ laisse passer une part importante des malins. La balanced accuracy varie aussi plus d'un fold à l'autre que l'AUC, de 0,781 à 0,929 contre 0,923 à 0,982.

4 Stabilité de la sélection des variables

La stabilité est mesurée par la classe `Stability`, à partir des 15 modèles de l'évaluation, en trois étapes.

1. Les dix variables retenues par chaque modèle sont enregistrées dans la classe `FeatureSelection`, sous la forme d'un ensemble de noms de variables.
2. Pour chacune des 30 variables, le nombre de modèles dont l'ensemble la contient donne sa fréquence de sélection, sur 15.
3. Pour chaque paire de modèles, la similarité de Jaccard est le nombre de variables communes aux deux ensembles, divisé par le nombre de variables présentes dans au moins un des deux. Elle vaut 1 pour deux ensembles identiques. Sa moyenne est calculée sur les 105 paires distinctes de modèles, et aussi, pour chaque modèle, sur ses 14 paires avec les autres.

La figure 7 donne le nombre de modèles qui ont retenu chaque variable.

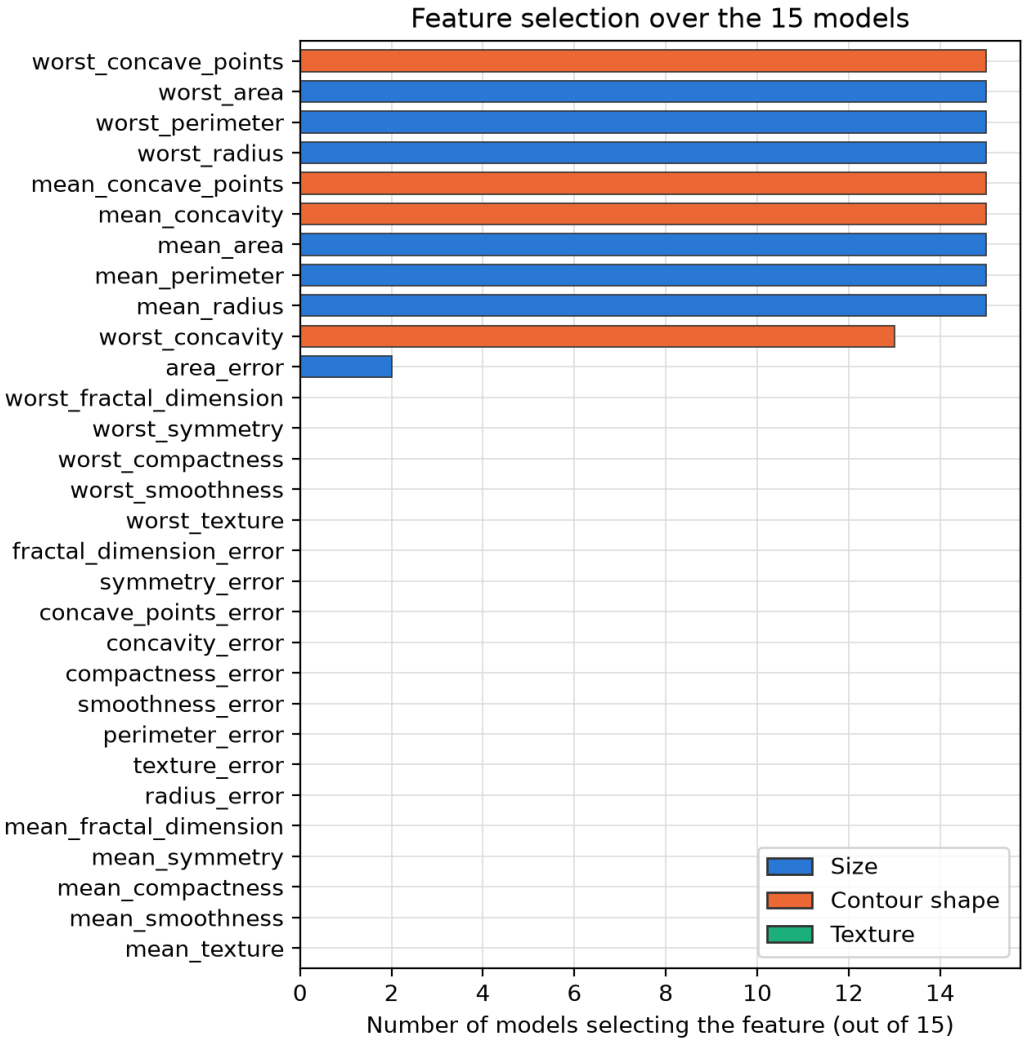


FIGURE 7 – Nombre de modèles, sur les 15, qui sélectionnent chaque variable (`results/figures/4_selection_frequencies.png`).

Neuf variables sont retenues par les 15 modèles. Seule la dixième place change, occupée 13 fois par `worst_concavity` et 2 fois par `area_error`, dans les modèles R1F1 et R2F3 (points orange de la figure 8). Aucune des 19 autres variables n'est jamais choisie, et aucune variable de texture n'apparaît. Dans le modèle exemple (figure 4), les neuf premières variables ont un poids d'au moins 0,980, et `area_error`, dixième avec 0,922, reste proche de `worst_concavity`, onzième.

La figure 8 met en regard, pour chacun des 15 modèles, sa similarité de Jaccard moyenne avec les 14

autres et sa balanced accuracy.

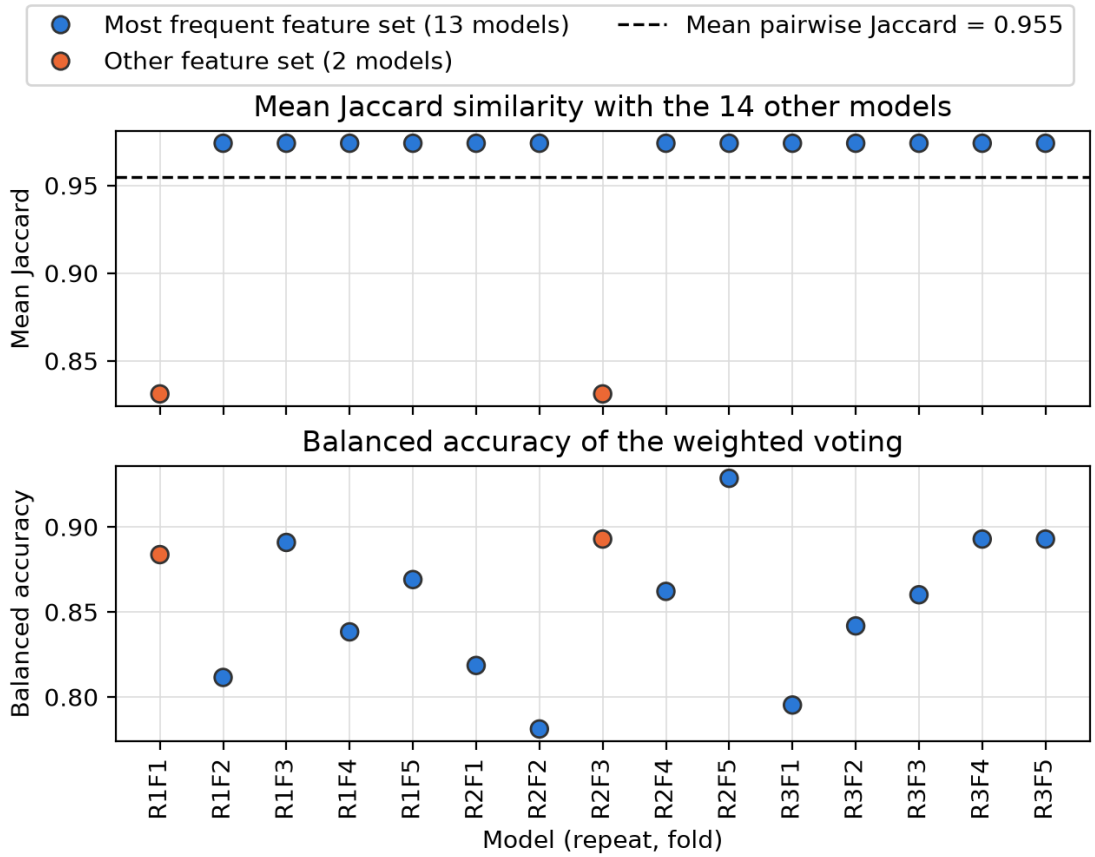


FIGURE 8 – Similarité de Jaccard moyenne de chaque modèle avec les 14 autres (en haut) et balanced accuracy du vote pondéré (en bas). La couleur indique si le modèle retient l'ensemble de variables le plus fréquent (`results/figures/4_model_stability.png`).

La similarité de Jaccard moyenne sur les 105 paires distinctes de modèles vaut 0,955, ce que montre la ligne pointillée de la figure.

Le haut de la figure 8 ne montre que deux niveaux de Jaccard. Les 13 modèles qui partagent le même ensemble ont tous le même Jaccard moyen, plus élevé que celui des deux autres, R1F1 et R2F3, qui diffèrent d'une variable. Le bas de la figure ne suit pas ces deux niveaux. Avec exactement les mêmes dix variables, les 13 premiers obtiennent une balanced accuracy allant de 0,781 (R2F2) à 0,929 (R2F5), soit un écart de 0,148, pour une moyenne de 0,853. Ce même ensemble de variables donne aussi le moins bon et le meilleur modèle en AUC, de 0,923 (R2F2) à 0,982 (R2F5). Les deux modèles qui retiennent `area_error` obtiennent 0,884 (R1F1) et 0,893 (R2F3), au-dessus de la moyenne des 15 modèles, 0,857. Ils se placent parmi les six meilleurs, et ne correspondent donc à aucun des moins bons folds. La stabilité de la sélection et celle des prédictions ne coïncident donc pas. Une sélection stable indique que la méthode retient toujours les mêmes mesures, pas que ses performances sont constantes.

5 Comparaison avec la régression logistique

La comparaison est faite par la classe `Comparison`, à partir des 15 folds de l'évaluation, en trois étapes.

1. Pour chaque fold, un modèle de la classe `LogisticRegression` du projet est entraîné sur le jeu d'entraînement, avec les 30 variables. Il ajuste d'abord un `StandardScaler` de scikit-learn sur ce jeu, qui ramène chaque variable à une moyenne de 0 et un écart-type de 1. Il entraîne ensuite la régression logistique de scikit-learn, `LogisticRegression(solver="liblinear", C=1.0, max_iter=1000)`, sur ces variables standardisées, sans pondération des classes ni réglage d'hyperparamètre.
2. Sur le jeu de validation, les variables sont standardisées avec le même `StandardScaler`, puis le modèle donne la probabilité d'être malin de chaque patient. Un patient est prédit malin lorsque cette probabilité atteint 0,5.
3. La classe `Metrics` calcule l'AUC, avec cette probabilité comme score, la balanced accuracy et la matrice de confusion, comme pour le vote pondéré. La moyenne et l'écart-type de l'AUC et de la balanced accuracy sont ensuite calculés sur les 15 folds.

La figure 9 compare les deux méthodes sur chacun des 15 modèles.

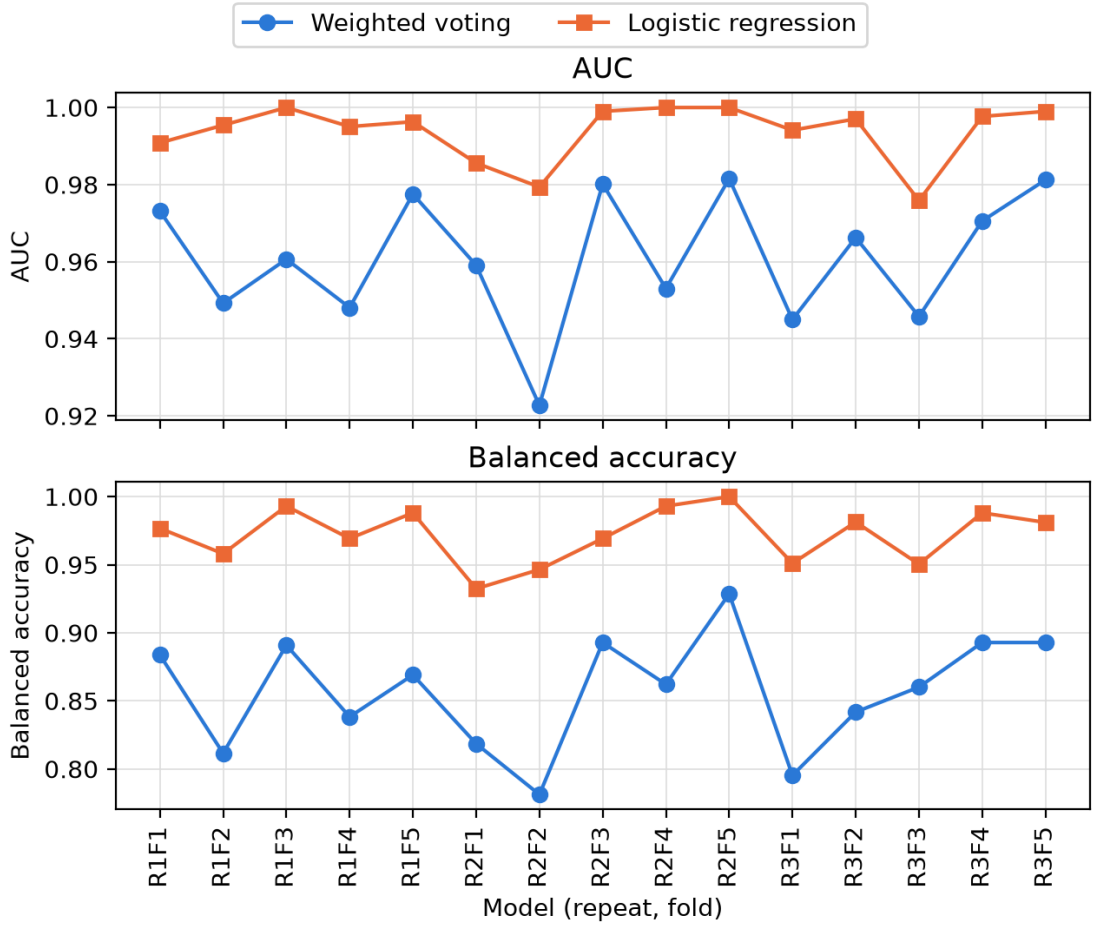


FIGURE 9 – AUC (en haut) et balanced accuracy (en bas) du vote pondéré et de la régression logistique sur les 15 mêmes découpages (`results/figures/5_fold_metrics.png`).

La régression logistique obtient une AUC moyenne de 0,994 contre 0,961, et une balanced accuracy moyenne de 0,972 contre 0,857. Elle fait mieux sur chacun des 15 modèles et pour les deux métriques, ce qui montre que l'écart ne dépend pas d'un découpage particulier. Ses résultats sont aussi deux fois moins dispersés, avec des écarts-types de 0,008 et 0,020 contre 0,017 et 0,042.

Une courbe ROC trace la sensibilité en fonction de la part des bénins classés malins, pour tous les

seuils possibles, et l'AUC est l'aire sous cette courbe. La figure 10 superpose les courbes des 15 modèles de chaque méthode.

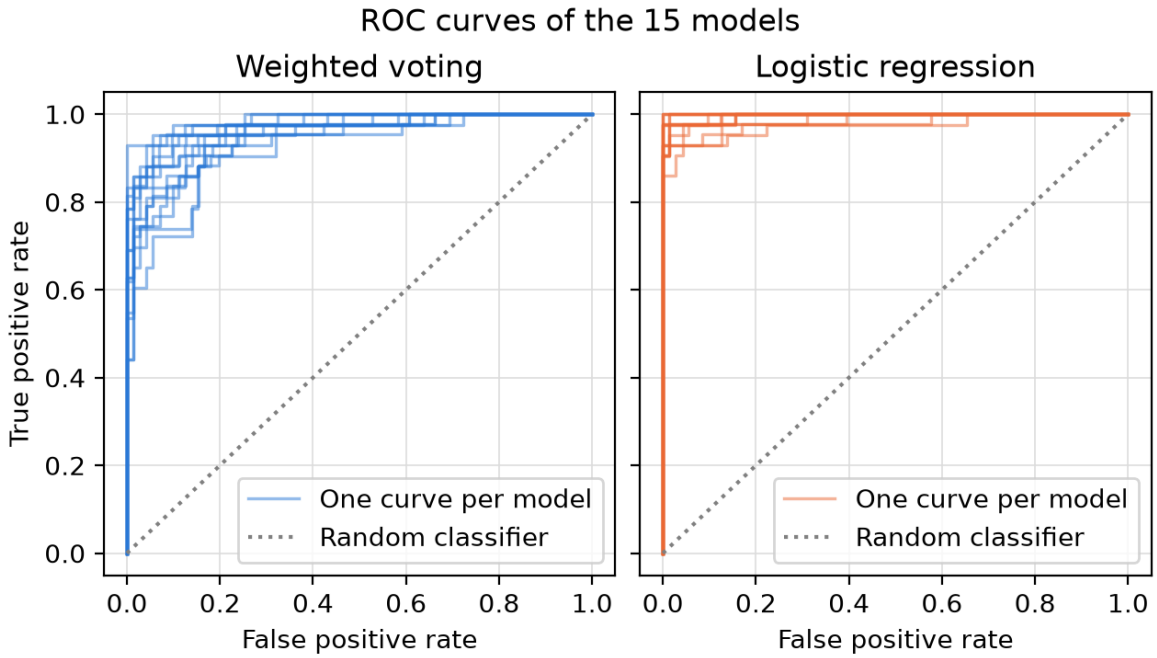


FIGURE 10 – Courbes ROC des 15 modèles du vote pondéré (à gauche) et de la régression logistique (à droite). La diagonale pointillée correspond à un classement au hasard (`results/figures/5_roc_curves.png`).

Les courbes de la régression logistique montent presque verticalement, avec une AUC d'au moins 0,976 et égale à 1 pour 3 modèles. Celles du vote pondéré montent moins vite et s'écartent davantage les unes des autres, avec une AUC de 0,923 à 0,982. L'écart entre les deux méthodes est pourtant plus de trois fois plus grand en balanced accuracy (0,115) qu'en AUC (0,033). Les deux méthodes diffèrent sur trois points. La régression logistique apprend son propre terme constant, qui joue le rôle de seuil, alors que le vote pondéré impose le point milieu des moyennes. Elle travaille sur des variables standardisées, où aucune variable ne domine par son unité, alors que les deux variables d'aire dominent le vote du modèle exemple (figure 3). Enfin, elle estime tous les coefficients ensemble et tient compte des variables redondantes, alors que le vote pondéré additionne dix variables dont six mesurent la taille du noyau.

6 Conclusion sur la question clinique

Le vote pondéré n'est pas recommandable en l'état pour prédire le diagnostic d'un patient. Il manque 10 des 43 malins du modèle exemple (figure 5), et sa balanced accuracy moyenne de 0,857 reste loin des 0,972 de la régression logistique, qui fait mieux sur chacun des 15 modèles (figure 9). Une partie de ces malins ont un vote au milieu de ceux des bénins (figure 6), et le vote repose presque uniquement sur l'aire du noyau (figure 3). Or un faux négatif signifie qu'une masse maligne est considérée comme bénigne, ce qui peut retarder la prise en charge du cancer.

Même la régression logistique ne suffit pas pour un usage clinique. Les modèles n'ont été testés que sur les 569 patients d'une même étude, sans les 54 patients de test externe, et le tableau n'indique ni le centre, ni la date du prélèvement, ni la façon dont chaque diagnostic a été confirmé. Les résultats ne portent en outre que sur le diagnostic d'une masse déjà prélevée, pas sur le dépistage, le pronostic ou la réponse au traitement.

Avant un usage clinique, il faudrait donc standardiser les variables avant le vote, choisir le seuil sur les données d'entraînement pour détecter une part fixée à l'avance des malins, puis tester le modèle sur des patients d'autres centres.

7 Reproductibilité de la méthode de l'article

La version appliquée ici reprend le poids et le vote de l'article de Golub (section 2). Trois points du texte de l'article empêchent de reproduire exactement la méthode, ou ne se transposent pas à WDBC.

L'article normalise chaque valeur par la moyenne et l'écart-type du jeu d'entraînement, sans préciser si le point milieu est calculé avant ou après cette normalisation. La version appliquée ici ne normalise pas, et les deux variables d'aire dominent le vote, même si les dix poids sont proches (figures 3 et 4).

L'article retient autant de gènes plus élevés dans chaque classe, 25 de chaque côté, et qualifie lui-même ce nombre de 50 de « quelque peu arbitraire ». Sur WDBC, seules trois variables ont une AUC inférieure à 0,5, toutes entre 0,445 et 0,485 (figure 2). Avec dix variables, il faudrait en retenir cinq plus élevées chez les bénins, ce que ces données ne permettent pas.

L'article ne classe pas un échantillon dont la force de prédiction est inférieure à 0,3, un seuil justifié par une analyse renvoyée à son site web. Ses 100 % de réussite ne portent donc que sur les échantillons classés, 36 des 38 en validation croisée et 29 des 34 du jeu indépendant. La version appliquée ici classe tous les patients, et sa balanced accuracy de 0,857 ne se compare donc pas directement à ces 100 %.

L'article aurait dû préciser dans son texte la normalisation du point milieu, la justification chiffrée du seuil de 0,3, le calcul exact des écarts-types, le choix entre deux gènes de même poids, et la répartition des gènes lorsque l'une des classes a peu de variables plus élevées chez elle.

Bibliographie

— **Golub TR et al. (1999).** Molecular classification of cancer : class discovery and class prediction by gene expression monitoring. *Science*, 286(5439), 531–537.
https://doi.org/10.1126/science.286.5439.531

— **Wolberg W, Mangasarian O, Street N, Street W.** Breast Cancer Wisconsin (Diagnostic). UCI Machine Learning Repository.
https://doi.org/10.24432/C5DW2B

— **Street WN, Wolberg WH, Mangasarian OL (1993).** Nuclear feature extraction for breast tumor diagnosis. *IS&T/SPIE Symposium on Electronic Imaging*, 1905, 861–870.
https://doi.org/10.1117/12.148698

— **Wolberg WH, Street WN, Mangasarian OL (1994).** Machine learning techniques to diagnose breast cancer from image-processed nuclear features of fine needle aspirates. *Cancer Letters*, 77(2–3), 163–171.
https://doi.org/10.1016/0304-3835(94)90099-X

— **Pedregosa F et al. (2011).** Scikit-learn : machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
https://jmlr.org/papers/v12/pedregosa11a.html

Glossaire

AUC Aire sous la courbe ROC. Probabilité qu'un patient malin tiré au hasard reçoive un score plus élevé qu'un patient bénin tiré au hasard. Elle vaut 1 pour un classement parfait et 0,5 pour un classement au hasard, et ne dépend pas du seuil de décision. Une AUC inférieure à 0,5 signifie que le score est plus bas chez les malins.

Balanced accuracy Moyenne de la sensibilité et de la spécificité. Contrairement à l'accuracy, elle donne le même poids aux deux classes, quel que soit leur nombre de patients.

Classe positive Classe que le modèle cherche à détecter, ici la classe maligne, codée 1.

Courbe ROC Courbe de la sensibilité en fonction de la part des bénins classés malins, obtenue en faisant varier le seuil de décision.

Faux négatif Patient malin prédit bénin.

Fold Groupe de patients d'une validation croisée. Le fold de validation sert à évaluer le modèle, les autres folds forment le jeu d'entraînement.

Force de prédiction Dans l'article de Golub, écart entre le total des votes de la classe gagnante et celui de la classe perdante, divisé par leur somme.

Matrice de confusion Tableau qui croise le diagnostic réel et le diagnostic prédit, et compte les patients de chaque case.

Ponction à l'aiguille fine Prélèvement de cellules d'une masse à l'aide d'une aiguille fine, en vue d'un examen au microscope.

Régression logistique Modèle qui estime la probabilité d'appartenir à la classe positive à partir d'une combinaison linéaire des variables.

Seed Valeur qui initialise le générateur aléatoire, et rend le mélange des patients reproductible.

Sensibilité Part des patients malins prédits malins.

Similarité de Jaccard Nombre d'éléments communs à deux ensembles divisé par le nombre d'éléments présents dans au moins un des deux.

Spécificité Part des patients bénins prédits bénins.

Standardisation Transformation d'une variable pour lui donner une moyenne de 0 et un écart-type de 1.

Validation croisée stratifiée Découpage des patients en groupes qui conservent chacun la proportion de chaque classe, chaque groupe servant tour à tour de jeu de validation.